
Análise de Modelos de Aprendizagem de Máquina para Detecção do Pé Diabético com Base em Temperaturas Plantares

Donnavan Souza de Carvalho
Departamento de Computação
Universidade Federal do Ceará
donnavansouza@alu.ufc.br

Guilherme Monteiro Bessa
Departamento de Computação
Universidade Federal do Ceará
guilherme.montb@alu.ufc.br

Luís Antonio Lopes Bezerra
Departamento de Computação
Universidade Federal do Ceará
luislopesbezerra@alu.ufc.br

Marcos Iuri Alves de Holanda
Departamento de Computação
Universidade Federal do Ceará
iurihol100@alu.ufc.br

Resumo

O pé diabético é um grave problema de saúde associado ao diabetes, podendo levar à diversas complicações. Em vista disso, há um crescente interesse em aplicar técnicas de Aprendizado de Máquina para identificar essa condição. No presente trabalho, propomos e avaliamos cinco modelos para a tarefa de diagnosticar o pé diabético com base em dados biométricos. Nossos resultados, em concordância com a literatura, reforçam que a Aprendizagem de Máquina é uma opção promissora para monitorar o pé diabético, mas também mostram que existem desafios significativos, como a baixa quantidade de dados, principalmente do grupo de controle.

1 Introdução

Nos últimos anos, a academia tem demonstrado crescente interesse no tratamento e prevenção da condição do pé diabético, uma complicação grave do diabetes. Essa condição afeta os pés devido à neuropatia (danos nos nervos) e à má circulação sanguínea, aumentando significativamente o risco de feridas, infecções e, em casos graves, amputação. Muitas dessas propostas utilizam Inteligência Artificial (IA) e Aprendizagem de Máquina (ML) para automatizar a classificação, identificação, tratamento e, frequentemente, a prevenção [Guan et al., 2024, Popa et al., 2023]. Provendo não só um auxílio à atividade médica, mas também inova ao permitir soluções que seriam inviáveis sem o auxílio computacional.

Além disso, tem-se buscado identificar fatores que denotam essa condição, visando aprimorar a capacidade de diagnóstico [Sacco et al., 2023, Chemello et al., 2022]. Anteriormente, a identificação era frequentemente custosa ou inviável, devido à limitação de profissionais capacitados, à falta de acesso a cuidados especializados, ou à negligência pessoal e familiar, entre outros desafios. Nesse contexto, metodologias [Filipe et al., 2022] propostas têm, muitas vezes, como objetivo primário auxiliar ou até mesmo remover completamente a dependência humana do processo de diagnóstico, por meio de artifícios computacionais avançados e que cada vez mais estão presentes no cotidiano social.

Por esse motivo, IA e ML têm sido empregadas para analisar dados biométricos, como temperatura e umidade, permitindo classificações automatizadas e inteligentes das condições, com resultados inéditos.

Se antes era necessário um acompanhamento médico periódico, que muitas vezes se configurava inviável devido a diversas razões como a distância, dificuldade de locomoção, entre outras, agora o acompanhamento médico pode ser feito a distância e de maneira simplificada com o uso de algoritmos e propostas de ML que muitas vezes podem sugerir conclusões, gerar alertas, classificar e prever agravamentos ou desenvolvimentos da condição. Em muitos casos, o monitoramento pode ser realizado até mesmo pelo próprio paciente e seus familiares, proporcionando maior praticidade, facilidade e, em geral, um acompanhamento aprimorado da doença [Kairys et al., 2023].

Motivados por esses fatores, este artigo apresenta os resultados de uma análise independente utilizando modelos de Aprendizagem de Máquina. Estes modelos foram selecionados com base em propostas reais identificadas na literatura e demonstraram aplicabilidade em soluções práticas com dados autênticos. Como entrada, os modelos utilizaram um conjunto de dados (dataset) composto por medições reais de temperatura dos pés de pacientes com diabetes e de indivíduos saudáveis [Hernandez-Contreras et al., 2019], permitindo testar a capacidade dos modelos de ML em classificá-los corretamente como saudáveis ou não saudáveis.

Este artigo está dividido da seguinte maneira. Na Seção 2, apresentamos a fundamentação teórica do problema, incluindo a descrição técnica, o conjunto de dados e a revisão dos principais trabalhos relacionados. A Seção 3 descreve a metodologia adotada, abordando os objetivos, o processo de tratamento dos dados, os modelos utilizados, a normalização e as métricas de avaliação. Na Seção 4, discutimos os experimentos realizados, os resultados obtidos e suas respectivas análises. Por fim, a Seção 5 traz uma discussão geral, limitações enfrentadas e considerações finais.

2 Fundamentação Teórica

2.1 Descrição Técnica do Problema

A identificação precoce de complicações nos pés de pacientes diabéticos, como úlceras plantares e neuropatia periférica, é um tema de grande relevância clínica. Nesse contexto, o uso de imagens térmicas (termogramas) da região plantar tem se mostrado uma abordagem promissora e não invasiva para o monitoramento da saúde vascular e neurológica dos membros inferiores.

Este trabalho propõe o desenvolvimento de modelos de aprendizado de máquina como SVM (Support Vector Machine), KNN (K-Nearest Neighbours), Redes Neurais, Árvores de Decisão e Regressão Logística (RL) para prever a presença de alterações compatíveis com o pé diabético a partir de dados térmicos. A hipótese central é que a temperatura plantar média e regional, especialmente em áreas irrigadas por artérias específicas (angiossomas), é um indicador confiável de risco clínico, como sugerido por estudos anteriores [Filipe et al., 2022].

2.2 Descrição do Conjunto de Dados

O dataset utilizado é o *Plantar Thermogram Database for the Study of Diabetic Foot Complications* [Hernandez-Contreras et al., 2019], um repositório público composto por registros térmicos plantares coletados com câmeras infravermelhas de alta precisão, obtidos de 167 indivíduos (122 pacientes com diabetes e 45 indivíduos saudáveis).

Os dados foram estruturados em um arquivo tratado contendo 166 amostras e 13 colunas: 12 com características térmicas e 1 representando a classe (saudável ou não).

Atributos (entradas)

As 12 primeiras colunas correspondem à temperatura média em diferentes regiões da planta do pé direito e do pé esquerdo, respectivamente, organizadas segundo angiossomas anatômicos:

- Temperatura global do pé (General),
- Artéria Calcaneana Lateral (LCA),
- Artéria Plantar Lateral (LPA),
- Artéria Calcaneana Medial (MCA),
- Artéria Plantar Medial (MPA),
- Índice TCI (Thermal Circulatory Index).

Classe (target)

A última coluna indica a classe binária associada à condição clínica do paciente:

- 0: Paciente saudável (grupo controle),
- 1: Paciente com diagnóstico de diabetes.

2.3 Revisão de Trabalhos Relacionados

Diversos estudos têm abordado o reconhecimento de alterações associadas ao pé diabético por meio de imagens térmicas. A escolha dos modelos neste trabalho se baseou em sua ampla utilização na literatura e em características como interpretabilidade, custo computacional e desempenho em bases moderadas.

Filipe et al. [Filipe et al., 2022] introduzem o *Thermal Change Index* (TCI) para detectar disparidades térmicas entre pés. Usando esse índice, foi possível criar modelos como Regressão Logística, SVM e Random Forest, com destaque para a RL em atributos como TCI e temperatura média.

Ramírez et al. [Ramírez Martínez et al., 2024] usaram uma base com 334 termogramas, avaliando ANN, SVM, KNN e RL. As redes neurais destacaram-se pela estabilidade, com acurácia de 85%, destacando a importância da escolha de variáveis térmicas adequadas.

Tiwari et al. [Tiwari et al., 2023] exploraram modelos como KNN, Naïve Bayes e RL, obtendo até 88% de acurácia com normalização apropriada. O KNN teve destaque pela leveza e boa performance.

Ainda em [Tiwari et al., 2023], o uso de Árvores de Decisão se destacou pela transparência no processo decisório, motivando sua inclusão neste estudo como modelo interpretável.

Rosenbaum et al. [Rosenbaum et al., 2024] analisaram o uso de SVM após redução de dimensionalidade via PCA, atingindo 90% de acurácia e 100% de especificidade, com metodologia similar à adotada aqui.

Por fim, Pereira et al. [Pereira et al., 2021] compararam AdaBoost, SVM, RL e CNN, e observaram que modelos simples como AdaBoost e RL podem superar redes profundas em bases limitadas, atingindo até 97% de F1-score.

3 Metodologia

3.1 Objetivos

Como descrito na introdução, nosso objetivo é analisar medições de temperatura e umidade dos pés de pessoas com pé diabético, aplicando técnicas de Aprendizagem de Máquina, a fim de determinar sua efetividade para diagnosticar uma pessoa como saudável ou não saudável. Nesta seção, descreveremos quais métodos aplicamos em nossa análise.

3.2 Conjunto de Dados

Primeiramente, descreveremos a obtenção e o tratamento dos dados. Como já descrito na introdução, os dados que utilizamos são os disponibilizados por Hernandez-Contreras et al. [2019]. Após obtermos o conjunto completo de dados, focamos em isolar as informações relevantes para a nossa análise. O *dataset* original continha uma planilha com as informações que nos interessavam já extraídas dos termogramas. Em vista disso, o único processo de tratamento de dados necessário foi extrair o conteúdo da planilha em um arquivo CSV para que os modelos pudessem carregá-lo com mais facilidade.

3.3 Divisão dos Dados

Após preparar os dados, é necessário separar um conjunto para o treino e outro conjunto para o teste. No nosso caso, esse passo tem uma relevância maior, pois temos uma quantidade muito pequena de dados. Nesse contexto, optamos por reservar 20% do *dataset* para o teste em todos os experimentos, visando um equilíbrio entre ter exemplos suficientes para realizar o treinamento e

ter casos de teste suficientes para avaliar o desempenho dos modelos. Para fazer a divisão, usamos a função *train_test_split* do Scikit Learn, com estratificação, ou seja, preservando a proporção de positivos e negativos do conjunto de dados antes da divisão.

3.4 Construção dos Modelos

Feita a divisão dos dados, prosseguimos com a construção dos modelos. Utilizamos cinco técnicas diferentes em nossa análise: Regressão Logística, Redes Neurais, SVM, KNN e Árvore de Decisão. Para cada uma das técnicas, realizamos um *grid search* a fim de encontrar os melhores hiper-parâmetros, usando uma validação cruzada estratificada de 10 *folds*. Além disso, nossos dados são desbalanceados, uma vez que os casos positivos (com a doença) superam o grupo de controle em aproximadamente três vezes. Para mitigar esse problema, testamos três técnicas de balanceamento: *Random Over Sampling*, *Random Under Sampling* e *SMOTE*, adotando aquela que proporcionou os melhores resultados. Por fim, observamos também a normalização dos dados em todos os passos, caso fosse necessário para o modelo em questão.

Uma vez que já descrevemos os modelos e técnicas que utilizamos, discutiremos alguns detalhes de implementação importantes. Todos os modelos foram implementados na linguagem Python. As bibliotecas que utilizamos foram: NumPy, Scikit Learn, Matplotlib, Seaborn, Imblearn e Pytorch. Todas os modelos utilizam a implementação do Scikit Learn, exceto pela Rede Neural, que implementamos com o Pytorch. Quanto ao funcionamento do nosso código, após carregar os dados e dividi-los em treino e teste, criamos um *pipeline* do Imblearn, que automatiza as operações de balanceamento e normalização, para cada modelo e executamos o *grid search* com validação cruzada estratificada fornecido pelo Scikit Learn. Com os hiper-parâmetros determinados, treinamos o melhor modelo obtido e o testamos nos dados de teste, gerando os resultados finais.

3.5 Normalização

O processo de normalização é essencial para a maioria dos modelos de Aprendizagem de Máquina, uma vez que a escala de um atributo não deve, geralmente, influenciar em sua relevância para o modelo. Portanto, é usual aplicar alguma transformação para deixar todos os atributos em uma escala similar. No nosso caso, escolhemos o *StandardScaler* do Scikit Learn, o qual realiza a transformação

$$x_{norm} = \frac{x - \mu}{\sigma},$$

onde μ é a média do atributo x e σ seu desvio padrão. Essa técnica gera dados com média 0 e desvio padrão 1, de modo que a escala dos atributos será a mesma. Aplicamos essa técnica de normalização aos dados de todos os modelos, exceto aos da Árvore de Decisão, pois ela é invariante à escala, logo a normalização seria redundante.

3.6 Métricas

Como estamos tratando de dados clínicos desbalanceados, escolhemos como métricas para avaliação do nosso modelo o *F1 score* e a AUC (apenas no teste), conforme o recomendado em Filipe et al. [2022], além da acurácia, da precisão e da revocação. A acurácia é a razão entre o número total de acertos do modelo e o número de casos. A precisão mede quão certas estão as predições positivas do modelo. A revocação mede quantos verdadeiros positivos o modelo identificou dentre todos os casos positivos. O *F1 score* é uma métrica que combina a precisão e a revocação por meio de uma média harmônica. As fórmulas das métricas descritas são

$$\begin{aligned} \text{acuracia} &= \frac{TP + TN}{TP + TN + FP + FN} \\ \text{precisao} &= \frac{TP}{TP + FP} \\ \text{revocacao} &= \frac{TP}{TP + FN} \\ F_1 &= \frac{2}{\text{precisao}^{-1} + \text{revocacao}^{-1}} = 2 \frac{\text{revocacao} \times \text{precisao}}{\text{revocacao} + \text{precisao}}, \end{aligned}$$

onde TP representa o número de verdadeiros positivos, TN representa o de verdadeiros negativos, FP representa o de falsos positivos e FN representa o de falsos negativos. A métrica AUC (*Area Under the Curve*) representa a área sob a curva ROC, que é um gráfico da proporção de verdadeiros positivos em função da proporção de falsos positivos obtidos pelo modelo. Quando a área sob uma curva ROC é grande, isso significa que o modelo consegue uma boa taxa de verdadeiros positivos com uma pequena taxa de falsos negativos, o que reflete positivamente na performance geral do modelo.

4 Experimentos

Nessa seção faremos uma breve descrição dos experimentos computacionais realizados, bem como discutiremos os resultados obtidos e os principais gráficos e métricas gerados para a avaliação dos modelos, como função custo, acurácia, revocação, precisão, F1-score, curva ROC, matriz de confusão, entre outros. Em geral, tivemos uma acurácia semelhante entre todos os modelos, o que pode ser demonstrado pela similaridade das matrizes de confusão. Além disso, a maioria dos modelos tendem a prever mais falsos negativos do que falsos positivos, sendo que o mais balanceado nesse quesito foi o modelo SVM.

4.1 K-Nearest Neighbors (KNN)

O modelo KNN gerado teve um melhor desempenho com $k=1$, obtendo f1-score igual a 0,8465 no treino. Já no conjunto de testes tivemos um resultado de 0,77, como vimos na figura 1 da matriz de confusão.




Figura 1: Matriz de confusão para o KNN

4.2 Árvore de decisão

O modelo da árvore de decisão teve um melhor desempenho com o critério de entropia, sem limite de profundidade, sendo 1 o número mínimo de amostras por folha e 2 o número mínimo de amostras para ocorrer a divisão do nó, a figura 2 mostra a estrutura geral da árvore ótima. A figura 3, que mostra a importância de cada atributo mostra que a terceira coluna do dataset, ou seja, o angiossoma LPA do pé direito, possui uma relevância consideravelmente maior do que os outros. Em geral, o

modelo possuiu desempenho muito semelhante ao anterior, como mostra a matriz de confusão na figura 4 e a curva ROC na figura 5.

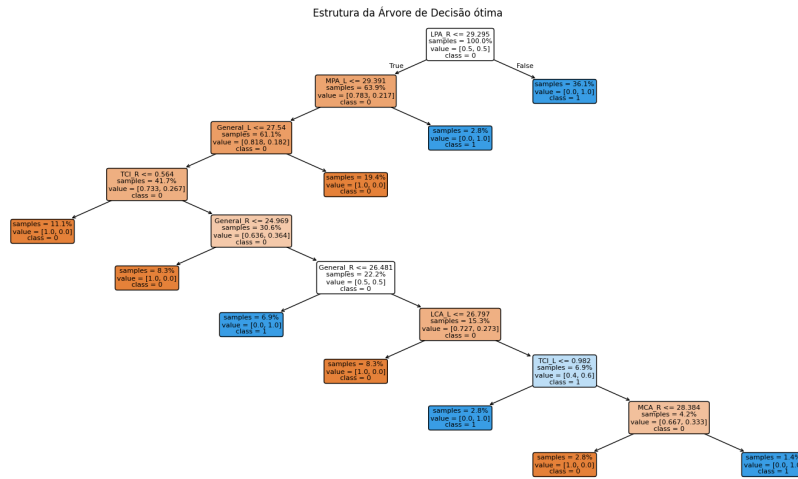


Figura 2: Estrutura da Árvore de Decisão ótima

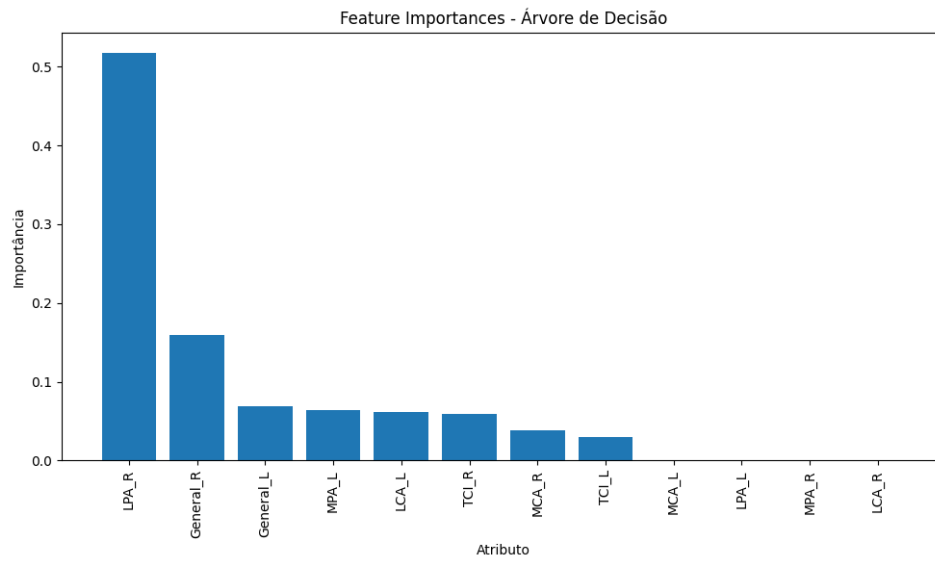


Figura 3: Grafico de barras da importância dos atributos




Figura 4: Matriz de confusão para a Árvore de Decisão

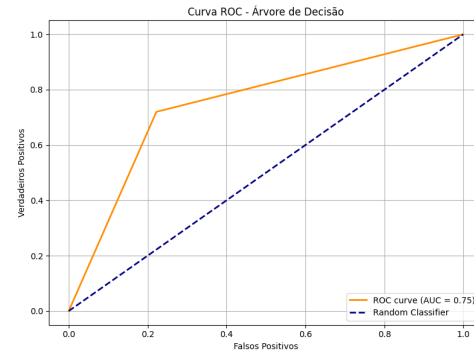


Figura 5: Curva ROC para a Árvore de Decisão

4.3 Máquina de Vetores de Suporte(SVM)

O modelo de SVM teve um melhor desempenho com os hiperparâmetros $C = 2$ e $\gamma = 8$. Foi o modelo com o segundo melhor desempenho em questão de acurácia, atrás apenas da regressão logística, e, como mencionado foi o modelo com o maior balanceamento entre falsos positivos e falsos negativos. As figuras 6 e 7 mostram, respectivamente, a matriz de confusão e a curva ROC para o SVM.




Figura 6: Matriz de confusão para a SVM

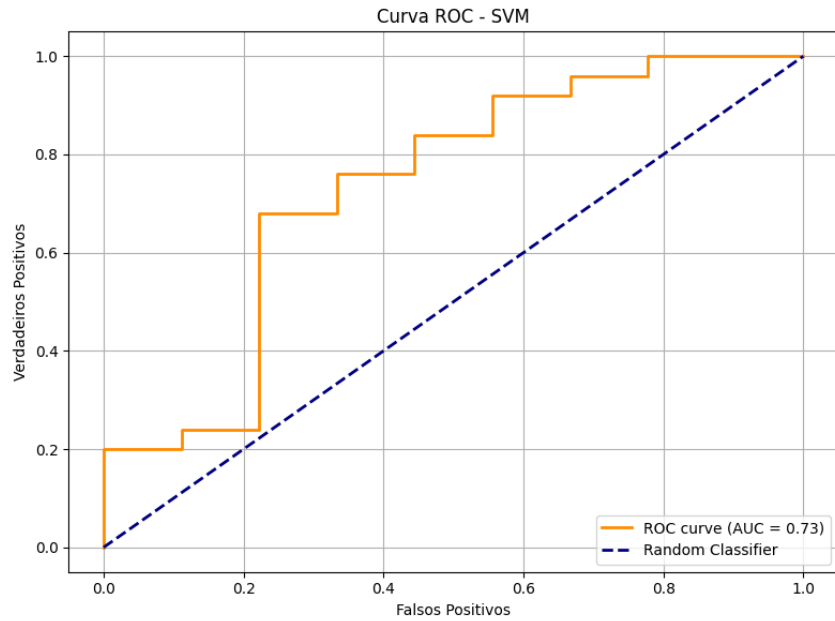


Figura 7: Curva ROC para a SVM

4.4 Regressão Logística

O modelo de regressão logística apresentou bom desempenho com os hiperparâmetros $C = 100$, Regularização L2 e algoritmo de otimização lbfgs. Obteve uma acurácia de 0,7436 nos dados de treino. O modelo apresentou um F1-score de 0,84, como evidenciado na matriz de confusão da figura 8. A figura 9 mostra a curva ROC para o modelo de regressão logística.




Figura 8: Matriz de confusão para a Regressão Logística

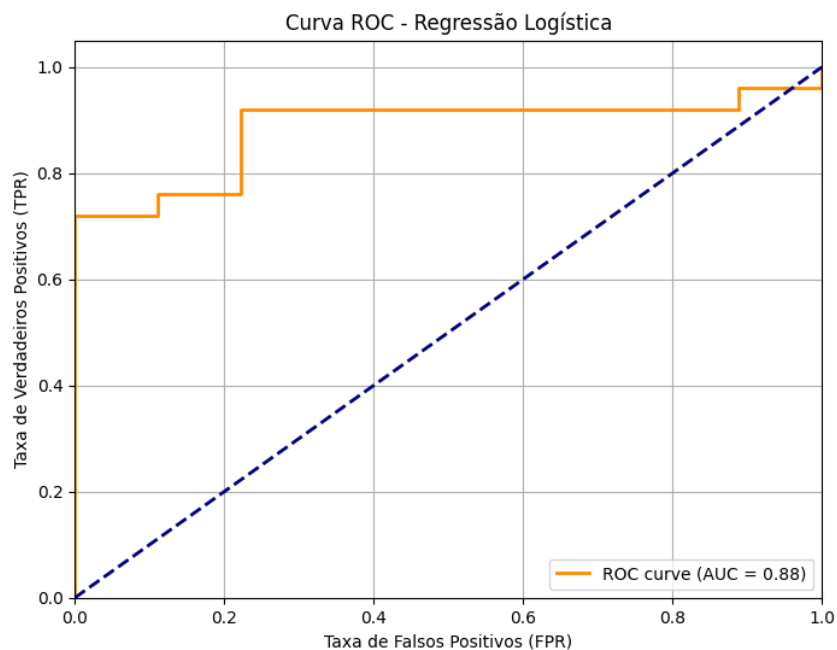


Figura 9: Curva ROC para a Regressão Logística

4.5 Rede Neural Artificial

O modelo de rede neural apresentou o melhor desempenho com os hiperparâmetros tamanho_de_batch = 16, número_de_épocas = 300, neurônios_ocultos = 16 e passo_de_aprendizado = 0,001. O modelo apresentou F1-score de 0,87, como indicado na matriz de confusão da figura 10. A função custo utilizada no modelo, que foi a entropia binária cruzada(Binary Cross-Entropy) convergiu ao longo das 300 épocas para um valor em torno de 0,4 como indicado no gráfico da figura 11. A figura 12 mostra, respectivamente, a curva ROC e a curva Precision-Recall para a rede neural.




Figura 10: Matriz de confusão para a Rede Neural




Figura 11: Função custo ao longo das épocas

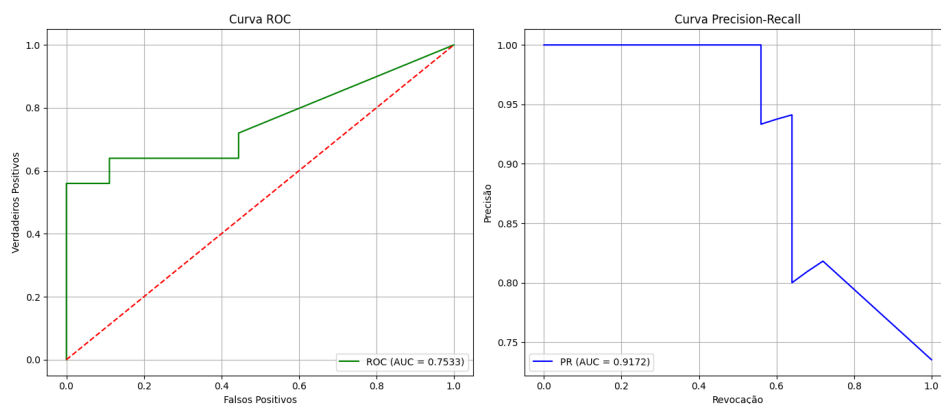


Figura 12: Curva ROC e Precision-Recall para a rede neural

4.6 Análise do modelo campeão

Com base na Tabela 1, o modelo de regressão logística apresentou o melhor desempenho geral entre os modelos avaliados. Esse modelo obteve a maior acurácia (**0,7941**) e o maior F1-score (**0,8444**), indicando um excelente equilíbrio entre precisão e revocação.

Dessa forma, a regressão logística foi considerada o *modelo campeão* nesta análise comparativa, superando os demais algoritmos tanto em desempenho preditivo quanto em estabilidade de métricas.

Tabela 1: Comparação das métricas dos modelos de classificação

Modelo	Acurácia	Revocação	Precisão	F1-score
SVM	0,7353	0,8000	0,8333	0,8163
Rede Neural	0,6765	0,7200	0,8182	0,7660
Árvore de Decisão	0,7353	0,7200	0,9000	0,8000
Regressão Logística	0,7941	0,7600	0,9500	0,8444
KNN	0,7059	0,6800	0,8947	0,7727

5 Conclusão

A difusão de ferramentas da área de IA e ML vêm sendo propagada em diversos meios, o da saúde sendo um dos que mais se beneficiam com o advento de novas técnicas que combinam modelos de

IA/ML com problemas e dificuldades médicas, com processos de diagnóstico e tratamento custosos ou inviáveis e com soluções inovadoras para tais processos.

No presente artigo, buscamos investigar o uso da temperatura de pés de pacientes saudáveis e com diabetes a fim de analisar os resultados obtidos por alguns modelos de ML que tinham como tarefa a classificação correta de ambos os grupos. Nessa investigação obtivemos resultados que caracterizamos como sendo bons/razoáveis (**84,4%** no F1-Score, **88%** no AUC, **95%** de Precisão, **76%** de Revocação e **79,4%** de Acurácia, obtidos através da Regressão Logística binária, modelo que apresentou os melhores resultados, no geral), mediante a resultados obtidos por outros trabalhos que utilizaram propostas similares [Filipe et al., 2022, Arteaga-Marrero et al., 2023].

Em trabalhos posteriores, ficou clara a necessidade de um maior pré-processamento dos dados, como denotado por [Filipe et al., 2022], que faz uma fase de pré-processamento caracterizada pelo uso de um algoritmo de agrupamento para dividir os termogramas — de onde os dados numéricos utilizados em nossa proposta foram inicialmente retirados [Hernandez-Contreras et al., 2019] — em cinco regiões diferentes, permitindo a distribuição de pixels da imagem entre as diferentes regiões.

Acreditamos que uma proposta mais robusta, desenvolvida por um maior período de tempo e com técnicas de pré-processamento mais avançadas, possa obter resultados melhores, como os obtidos por [Filipe et al., 2022], que apresentou métricas superiores: **92,6%** no F1-Score, **95,4%** no AUC, **89,2%** de Precisão, **92,3%** de Especificidade, **80,6%** de Revocação e **92,8%** de Acurácia (todos obtidos com o modelo de Regressão Logística binária, embora resultados similares tenham sido registrados pelos outros modelos utilizados na proposta), no estágio 1 do seu segundo modelo de classificação binária.

O desbalanceamento dos dados e, principalmente, a baixa quantidade de amostras no conjunto de dados figuram como os principais desafios e limitações encontrados no desenvolvimento desta proposta. Uma maior quantidade de dados balanceados seria de grande valia no desenvolvimento de um futuro trabalho, provendo um ambiente mais próximo do ideal, tanto para o aprimoramento de propostas já existentes quanto para o desenvolvimento de novas soluções.

Contribuição dos autores: a conceituação e delineamento do estudo foram realizados por D.S.C. e L.A.L.B. O pré-processamento dos dados ficou a cargo de L.A.L.B. A implementação dos modelos foi dividida da seguinte forma: KNN e Árvore de Decisão por D.S.C., SVM por L.A.L.B., Regressão Logística por G.M.B., e Rede Neural por M.I.A.H.

A redação das seções do artigo também foi distribuída entre os autores: introdução por D.S.C., fundamentação por G.M.B., metodologia por L.A.L.B., experimentos por M.I.A.H., e conclusão por D.S.C. A análise dos resultados, revisão textual e organização geral foram realizadas por todos os autores. A supervisão e curadoria do conteúdo ficaram sob responsabilidade de D.S.C. e L.A.L.B. Todos os autores aprovaram a versão final do manuscrito.

Referências

- N. Arteaga-Marrero, A. Hernández-Guedes, J. Ortega-Rodríguez, and J. Ruiz-Alzola. State-of-the-art features for early-stage detection of diabetic foot ulcers based on thermograms. *Biomedicines*, 11(12):3209, 2023. doi: 10.3390/biomedicines11123209.
- G. Chemello, B. Salvatori, M. Morettini, and A. Tura. Artificial intelligence methodologies applied to technologies for screening, diagnosis and care of the diabetic foot: A narrative review. *Biosensors*, 12(11):985, 2022. doi: 10.3390/bios12110985.
- V. Filipe, P. Teixeira, and A. Teixeira. Automatic classification of foot thermograms using machine learning techniques. *Algorithms*, 15(7):236, 2022. doi: 10.3390/a15070236.
- H. Guan, Y. Wang, P. Niu, Y. Zhang, Y. Zhang, R. Miao, X. Fang, R. Yin, S. Zhao, J. Liu, and J. Tian. The role of machine learning in advancing diabetic foot: a review. *Frontiers in Endocrinology*, 15:1325434, 2024. doi: 10.3389/fendo.2024.1325434.

- D. A. Hernandez-Contreras, H. Peregrina-Barreto, J. de J. Rangel-Magdaleno, and F. J. Renero-Carrillo. Plantar thermogram database for the study of diabetic foot complications. *IEEE Access*, 7:161296–161307, 2019. doi: 10.1109/ACCESS.2019.2951356.
- A. Kairys, R. Pauliukiene, V. Raudonis, and J. Ceponis. Towards home-based diabetic foot ulcer monitoring: A systematic review. *Sensors*, 23(7):3618, 2023. doi: 10.3390/s23073618.
- A. M. Pereira et al. Machine learning models for early detection of diabetic foot using thermogram images. *Computers in Biology and Medicine*, 2021.
- A. D. Popa, R. S. Gavril, I. V. Popa, L. Mihalache, A. Gherasim, G. Niță, M. Graur, L. I. Arhire, and O. Niță. Survival prediction in diabetic foot ulcers: A machine learning approach. *Journal of Clinical Medicine*, 12(18):5816, 2023. doi: 10.3390/jcm12185816.
- J. A. Ramírez Martínez et al. Implementation of a pattern classifier on thermograms from plantar region. *Lecture Notes in Networks and Systems*, 2024.
- D. Rosenbaum et al. Digital infrared thermography and machine learning for diabetic foot assessment. *PubMed*, 2024. PMID: 39610548.
- Isabel C. N. Sacco, Maria do Livramento Lucovéis Saraiva, Suely Rodrigues Thuler, and Maria Cândida Ribeiro Parisi. *Diagnóstico e prevenção de úlceras no pé diabético*. Sociedade Brasileira de Diabetes, 2023. ISBN 978-65-272-0704-7. doi: 10.29327/5412848.2024-11.
- S. Tiwari et al. A pilot study for profiling diabetic foot ulceration using machine learning. *International Journal of Diabetes in Developing Countries*, 2023.